

¿QUÉ DETERMINA EL PRECIO DE LA VIVIENDA EN EE.UU.?

Un análisis con regresión lineal y
regularización

SANTIAGO ALVAREZ TOSTADO ESTRADA
REGINA TAMAYO
ESTEFANIA MILKE


OBJETIVOS

General:

- Analizar y comparar diferentes especificaciones de modelos de regresión lineal para explicar y predecir el precio de viviendas en Estados Unidos


Específicos:

- Explorar y limpiar el conjunto de datos
- Construir tres arquitecturas de regresión lineal con 4 variantes cada una
- Comparar el desempeño de los modelos mediante el coeficiente de R^2 en entrenamiento y prueba.
- Analizar la significancia estadística de los factores en el modelo seleccionado.



METODOLOGÍA

Pipeline del proyecto



PALABRAS CLAVE

- Regresión lineal múltiple: técnica estadística utilizada para modelar la relación entre una variable dependiente y un conjunto de variables independientes.
- Coeficiente de R^2 : mide qué proporción de la variabilidad explica el modelo.
- Interacción de factores: es el efecto de una variable cuando ésta depende de otra (producto entre variables).
- Significancia estadística: $p\text{-value} < 0.05$ indica efecto relevante del predictor.
- Regularización: controla sobreajuste y multicolinealidad.
- Ridge (L2): reduce coeficientes sin eliminarlos por completo.
- Lasso (L1): puede eliminar variables.
- ElasticNet: combina Ridge y Lasso, buscando un balance.

DATASET

American Housing Dataset (2023)
~40,000 registros y 14 variables

Características físicas

- Precio de la vivienda (variable dependiente)
- Número de habitaciones
- Número de baños
- Superficie habitable de la propiedad
- Dirección

Ubicación

- Ciudad
- Estado
- Código postal
- Latitud/longitud

Contexto socioeconómico

- Densidad poblacional del área
- Ingreso medio del hogar en el código postal
- Población

PREPROCESAMIENTO

- Limpieza y validación de datos
- Eliminación de registros duplicados
- Transformación de variables categóricas (dummies por estado)
- Construcción de interacción: Living Space $\times$ Median Income
- Escalamiento de variables numéricas
- División de datos: 70% entrenamiento / 30% prueba

ARQUITECTURA DE LOS MODELOS

Modelo 1

Características físicas

- Living Space
- Beds
- Baths

Es el modelo más básico

Modelo 2

Geográfico

- Variables físicas
- Dummies por estado

Captura diferencias regionales en
el precio

Modelo 3


Completo

- Variables físicas
- Variables socioeconómicas
- Dummies geográficos
- Interacción: Living Space x
Median Income

El modelo mas complejo

RESULTADOS

Comparativa de R2 en el Set de Prueba (Capacidad de Generalización)



INTERPRETACIÓN

- Modelo 1 → tiene el desempeño más bajo, lo que indica que usar solo variables físicas básicas no es suficiente para explicar adecuadamente el precio.
- El Modelo 2 → mejora considerablemente al incluir variables geográficas, lo que confirma que la ubicación influye en el valor de la vivienda.
- El Modelo 3 → obtiene el mayor R^2 en prueba, demostrando que integrar variables socioeconómicas e interacciones mejora significativamente la capacidad predictiva.

No hay mejoras sustanciales después de las regularizaciones, lo que sugiere que el modelo no presenta un problema severo de sobreajuste o multicolinealidad.

MEJOR MODELO

- Incluye variables físicas, socioeconómicas y dummies por estado.
- Integra interacción: Living Space $\times$ Median Income.
- Logró el mayor poder predictivo ($R^2 \approx 0.596$).
- Variables mayormente significativas estadísticamente.
- Buen balance entre interpretación y capacidad predictiva.

CONCLUSION

- El precio de la vivienda depende tanto de características físicas como del contexto socioeconómico.
- Incluir variables como ingreso, densidad poblacional y ubicación mejora significativamente la capacidad explicativa.
- La interacción entre tamaño de vivienda e ingreso del área es clave para entender el mercado inmobiliario y es altamente significativa.
- La regularización (Ridge, Lasso, ElasticNet) no mejoró el desempeño, indicando bajo sobreajuste.
- La mayoría de variables del modelo final resultaron estadísticamente significativas ($p < 0.05$).

REFERENCIAS

- American Housing Dataset. (2023). Kaggle. Recuperado de:
<https://www.kaggle.com/datasets/jeremylarcher/american-house-prices-and-demographics-of-top-cities?resource=download>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.
- James, G., Witten, D., Hastie, T., Tibshirani, R., Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Cham: Springer. ISBN: 978-3-031-38746-3